

voice-sync-video · 音画同步视频生产管线

把"一段文案 + 一个产品"变成"配音和动画严格同步的成片"——场景边界 = TTS 句级时间戳，物理上杜绝音画跑偏。

作者：唐浩翔

形态：Agent 技能 (SKILL.md)

Remotion / HyperFrames · TTS · 句级时间戳

6 个人工硬闸门

1. 核心机制：时间戳是地基

TTS 合成时开启「字幕/时间戳」选项

- 官方句级 `time_begin / time_end` (如 `MiniMax subtitle_enable=true`)
- 换算帧号写入 `timing.ts` (唯一事实来源)
- 场景边界 = 句边界，字幕条读同一份时间戳

降级链：配音无时间戳 → ASR 回识别取句级时间戳 → 仍不行才按字数比例估算并明确标注"降级"

传统做法是按字数/感觉估算对齐，本管线把对齐建立在 TTS 官方时间戳上，音画同步从"调出来的"变成"结构保证的"。

2. 五条铁律

- 闸门必停**：标记  的环节必须停下来等用户拍板，禁止自作主张直出
- 时间戳是硬约束**：禁止按字数/感觉估算对齐
- 收费 TTS 先探针**：按量计费的 TTS 先发 1 条最短探针并**报价格**，用户点头才批量 (源自一次 10 分钟欠费 ¥21.5 的真实事故)
- 静帧 QA 必做**：全片渲染前必须出关键帧静图过目——印章压字、元素错位都是静帧抓出来的
- 配音变 → 节奏重排**：换音色/改稿后必须重取时间戳并重排每个场景的内部动画

3. 流程总览：13 步 · 6 个硬闸门

#	环节	闸门	干什么
A	事实核查+素材盘点		提取"可验证卖点"，记录出处
B	叙事方向卡		3-4 张方向卡 (判断流/团队流/演示流/纪录流)，用户选
C	口播稿+目标时长		文案优先于凑秒数
D	语音双问		先问"要不要配音"，再问"用哪种 TTS"
E	TTS 合成		整段一次出，不拆剪不加速
F	实际时长确认	 软	偏差 >10% 才打断用户
G	美术方向卡		风格库推荐 + 组件仓配候选，附"自定义"出口
H	分镜表	 软	场景×时间戳×演什么，一张表展示
I	场景开发		每句文案一个场景；优先取组件仓冻结组件改参数，新写的按 SOP 回收入库
J	静帧 QA		LLM 先按审美细则自评打分，<7 自动修 (最多 2 轮)，评分随图呈报
K	渲染		先 6 秒冒烟 (验音轨/运动)，再全片

L	成片 QA+终审		ffprobe 双流校验 + 抽帧报告，用户终审
M	清理+交付		留成片+配音+工程+溯源清单

设计哲学：**AI 不一股脑直出**。6 个硬闸门把"叙事方向、口播稿、配音、美术风格、静帧、终审"的决策权留给人类，自动化只负责执行层。

4. 组件资产复用 (motion-material-hub 对接)

- **23 个零依赖确定性组件**：帧驱动、任意帧可 seek、无 gsap/motion 依赖，复制进工程即用——时间参数全部帧数，对时间戳天然友好
- **六环调用法**：G 环节选款 → I 环节装配调参 → J 环节静帧 QA，形成闭环
- **审美评分细则 (taste-rubric)**：选款排序与静帧自评共用同一把尺，<7 分自动返修
- **新组件回收入库**：项目中新写的组件按 porting-sop 沉淀回组件仓，资产越用越厚

5. 技术栈与交付物

维度	选项 (让用户选，不猜)
引擎	Remotion (默认，实战验证过) / HyperFrames
画幅	16:9 1920×1080 (默认) / 9:16 / 1:1
帧率	30fps (默认) / 60fps (弱机讨论云端渲染)
字幕	同步字幕条 (默认) / 无字幕
配音	要 (选 TTS 链路) / 不要 (纯视觉片)

交付全家桶：成片 MP4 + 配音音频 + 字幕/时间戳文件 + 工程源码 + 溯源清单 (每项素材声明出处，概念素材明确标注)。